Docking Molecular

Modelamiento de complejos proteína–ligando y proteína–péptido

Osvaldo Yáñez

Centro de Modelación Ambiental y Dinámica de Sistemas

Magíster en Ciencias Biológicas y Químicas

Temario

I. Fundamentos
Reconocimiento molecular, termodinámica de la unión y planteamiento del problema

II. Preparación del sistema
Receptor, sitio de unión, mapas de energía y ligando

III. Algoritmos de búsqueda
Sistemáticos, Monte Carlo, algoritmos genéticos y búsqueda local

IV. Funciones de *scoring*
Campos de fuerza, empíricas, estadísticas y aprendidas

V. Evaluación y validación
RMSD, *clustering*, *redocking* y cribado virtual

VI. El caso de los péptidos
Por qué es un problema distinto y qué métodos existen

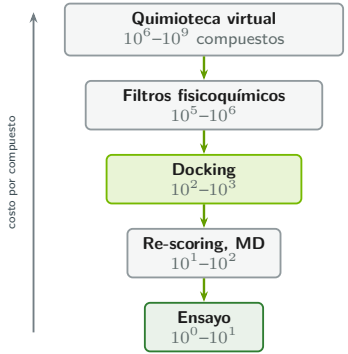
VII. Más allá del docking
Dinámica molecular, MM-PBSA y energía libre alquímica

Qué deberías poder hacer al final. Diseñar un protocolo de docking justificado, reconocer cuándo un resultado no es confiable, y explicar por qué un péptido no se acopla igual que una molécula pequeña.

Por qué modelamos la unión

- La actividad biológica de un fármaco empieza casi siempre por un **evento de unión**: una molécula reconoce un sitio específico de una proteína.
- El espacio químico sintetizable se estima en 10^{23}–10^{60} moléculas; ensayar experimentalmente incluso 10^{6} es costoso.
- El docking permite **ordenar** ese espacio: reducir millones de candidatos a decenas que valga la pena sintetizar y ensayar.
- También responde preguntas mecanísticas: *¿por qué* esta mutación abole la actividad, *qué* contactos explican la selectividad.

El docking no reemplaza al experimento: genera **hipótesis estructurales comprobables**. Su valor depende de que se interprete como tal.



El docking es el filtro que hace tratable el problema.

¿Qué es el docking molecular?

- Método computacional que predice la **orientación y conformación** que adopta un ligando al unirse a un receptor, y estima la **afinidad** de ese complejo.
- Entrega dos productos de naturaleza distinta:
  - la **pose**: una hipótesis geométrica;
  - la **puntuación**: una estimación energética.
- Predecir bien la pose y predecir bien la afinidad son problemas de dificultad muy diferente. El primero se resuelve razonablemente; el segundo sigue abierto.

Supuestos habituales. Receptor rígido o casi rígido, disolvente implícito, una sola pose representativa y temperatura fija. Cada uno es una aproximación que conviene tener presente.

Superficie del receptor

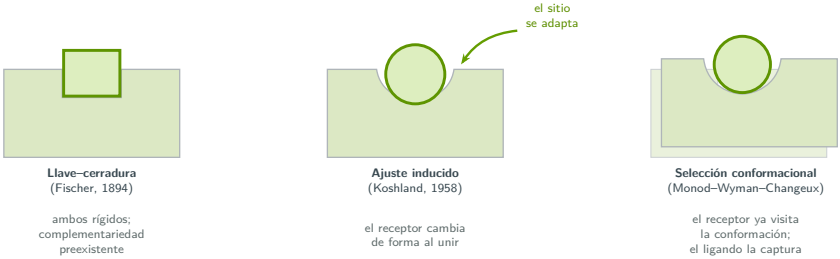


Corte frontal: el ligando en la cavidad



Superficie molecular calculada como isosuperficie de densidad atómica gaussiana. El corte frontal deja ver la cavidad y el ligando alojado en ella. Esquema estructural generado computacionalmente, no una estructura cristalográfica.

Modelos del reconocimiento molecular



Consecuencia práctica. El docking clásico implementa el modelo de llave–cerradura: el receptor se mantiene rígido. Cuando el sistema real sigue ajuste inducido o selección conformacional, una sola estructura del receptor no basta, y el docking sobre *ensembles* o el refinamiento con dinámica molecular dejan de ser un lujo para volverse necesarios.

Termodinámica de la unión

Equilibrio y constante de afinidad

$$\mathrm{P} + \mathrm{L} \rightleftharpoons \mathrm{PL}, \qquad K_a = \frac{[\mathrm{PL}]}{[\mathrm{P}][\mathrm{L}]} = \frac{1}{K_d}$$

Energía libre estándar de unión

$$\Delta G^\circ = -RT \ln\left(K_a c^\circ\right) = \Delta H^\circ - T\Delta S^\circ$$

Descomposición operativa

$$\Delta G_{\text{unión}} = \underbrace{\Delta G_{\text{inter}}}_{\text{contactos P–L}} + \underbrace{\Delta G_{\text{desolv}}}_{\text{retirar el agua}} + \underbrace{\Delta G_{\text{conf}}}_{\text{reorganización}} + \underbrace{\Delta G_{\text{mov}}}_{\text{entropía}}$$

Lectura: los términos se oponen entre sí. Un contacto excelente puede quedar anulado por el costo de desolvatar el sitio o por la entropía que pierde el ligando al inmovilizarse.

K_d	ΔG° / kcal mol^{-1}	Interpretación
1 mM	-4.1	fragmento débil
100 µM	-5.5	*hit* de cribado
1 µM	-8.2	*lead* razonable
10 nM	-10.9	fármaco típico
0.1 nM	-13.6	afinidad extrema

La regla práctica

$$\Delta G^\circ\ [\text{kcal mol}^{-1}] \;=\; -1.364\ \mathrm{p}K_d \qquad (T = 298\ \text{K})$$

Cada **1.36 kcal mol^{-1}** equivale a **un orden de magnitud** en K_d. Un error de 2 kcal mol^{-1} en la puntuación confunde un fármaco con un *hit* mediocre.

El problema formal: buscar y puntuar

El docking es un problema de **optimización global** en un espacio de configuraciones de alta dimensión.

Planteamiento

$$\left(\mathbf{t}^*, \boldsymbol{\Omega}^*, \boldsymbol{\tau}^*\right) = \arg\min_{\mathbf{t},\boldsymbol{\Omega},\boldsymbol{\tau}} E(\mathbf{t}, \boldsymbol{\Omega}, \boldsymbol{\tau}\,; \mathcal{R}) \qquad \text{con} \qquad d = 6 + N_{\text{rot}}$$

$\mathbf{t} \in \mathbb{R}^3$ traslación · $\boldsymbol{\Omega} \in SO(3)$ orientación · $\boldsymbol{\tau} \in [0, 2\pi)^N$ torsiones · $\mathcal{R}$ receptor

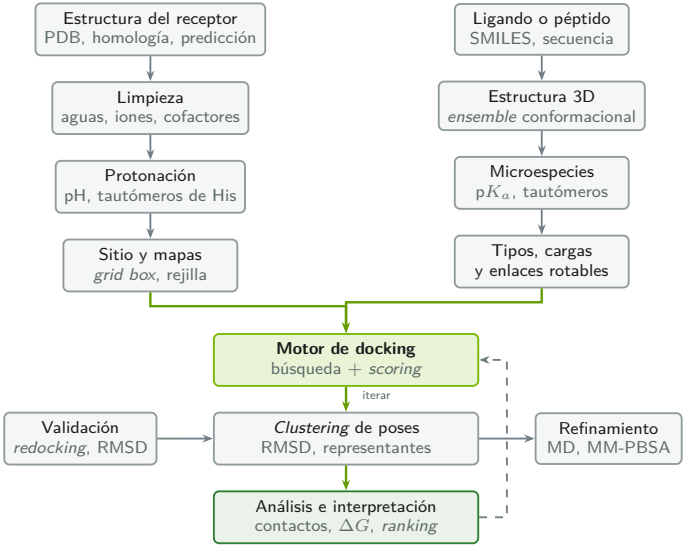
Qué grados de libertad se modelan y cuáles se congelan. Casi siempre: ligando flexible, receptor rígido, disolvente implícito.

Cómo se recorre el espacio. Determina si la pose correcta llega siquiera a generarse.

Cómo se puntúa cada configuración. Determina si, entre las poses generadas, se elige la correcta.

Los dos modos de fallar. *Error de muestreo*: la pose nativa nunca se genera. *Error de scoring*: la pose nativa se genera pero no es la de menor energía. Distinguirlos es el primer paso de cualquier diagnóstico: si al re-puntuar la pose cristalográfica obtienes una energía mejor que la de tu mejor predicción, tu problema es de *scoring*, no de búsqueda.

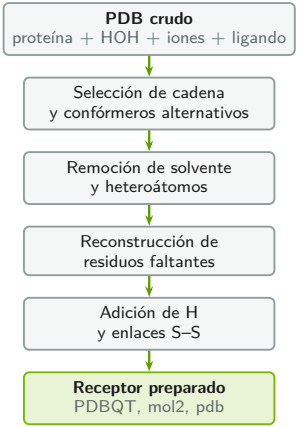
Flujo de trabajo general



Preparación del receptor I: limpieza estructural

- **Origen de la estructura**: cristalografía, crio-ME, RMN, modelo por homología o predicción. Conviene registrar la resolución y el factor R.
- **Limpieza**
  - aguas cristalográficas, iones y crioprotectores;
  - ligando co-cristalizado: se retira, pero se *guarda* como referencia para el *redocking*;
  - selección de una cadena y de un confórmero alternativo.
- **Reparación**: residuos y cadenas laterales faltantes, ocupancias parciales, extremos truncados.
- **Hidrógenos y enlaces disulfuro**: casi ninguna estructura de rayos X los resuelve; hay que añadirlos.

Las aguas que median puentes de hidrógeno dentro del sitio pueden ser parte del farmacóforo. Eliminarlas todas es una decisión, no un trámite: conviene justificarla y, si hay duda, probar ambas opciones.



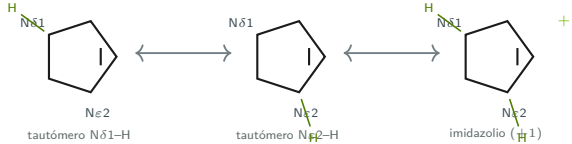
Preparación del receptor II: protonación y tautomería

Estados de ionización a pH 7.4

Residuo	pK_a	Carga	Nota
Asp / Glu	3.7–4.3	-1	aniónico
His	~ 6.0	$0/+1$	**crítico**
Cys	~ 8.4	$0/-1$	S–S o tiolato
Tyr	~ 10.1	0	dador de H
Lys	~ 10.5	$+1$	catiónico
Arg	~ 12.5	$+1$	catiónico

- El pK_a *local* se desplaza respecto al valor en disolución: un Asp enterrado junto a otro Asp puede protonarse.
- Herramientas: PROPKA, H++, PDB2PQR.
- Asignación de **cargas parciales**: Gasteiger, AM1-BCC o las del campo de fuerzas (AMBER, CHARMM).

Tautómeros de histidina



En los tres casos el anillo es el mismo; lo que cambia es **qué nitrógeno dona y cuál acepta** el puente de hidrógeno. En una tríada catalítica esa elección puede invertir por completo la pose predicha. Es, probablemente, la decisión de preparación con mayor impacto y la que más a menudo se toma por omisión.

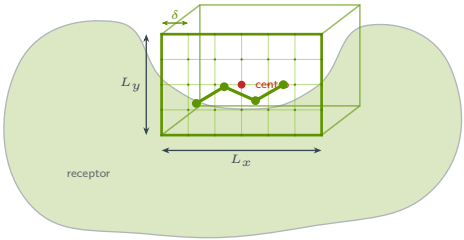
Definición del sitio de unión

- La búsqueda se restringe a una caja: centro (x_c, y_c, z_c), aristas (L_x, L_y, L_z) y espaciado δ, típicamente 0.375 Å.
- Las energías se **pre-calculan** en los nodos, una rejilla por tipo de átomo del ligando:

$$E_{\text{inter}} \approx \sum_{i \in \text{lig}} \mathcal{I}\Big[\, M_{t(i)}(\mathbf{r}_i) \,\Big]$$

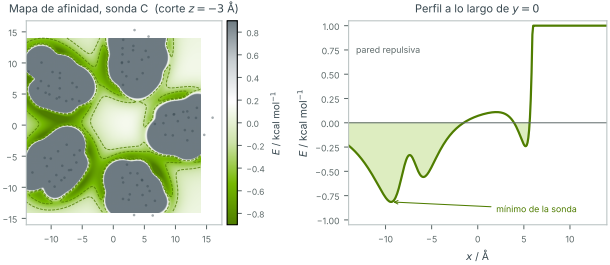
Lectura: M_t es el mapa del tipo t e $\mathcal{I}$ una interpolación trilineal. El costo por pose deja de depender del tamaño de la proteína.

- **Sitio conocido**: caja ajustada al bolsillo, con unos 5 Å de holgura sobre el ligando.
- **Sitio desconocido**: docking *ciego* o detección previa de cavidades (fpocket, SiteMap, CASTp).



Número de nodos $\approx \prod_k (L_k/\delta + 1)$: duplicar la arista multiplica por ~ 8 la memoria y el tiempo de pre-cálculo. Una caja innecesariamente grande no mejora el resultado; lo empeora, porque diluye el muestreo.

Mapas de afinidad: qué contiene realmente la rejilla



Lo que se evalúa en cada nodo

$$M_t(\mathbf{r}) = \sum_{j \in \mathcal{R}} \left[\varepsilon_{tj} \left(\left(\frac{r_0}{r_j} \right)^{12} - 2 \left(\frac{r_0}{r_j} \right)^{6} \right) + \frac{332\, q_j q_t}{\epsilon(r_j)\, r_j} \right]$$

El verde marca las regiones **favorables** para una sonda de carbono: tapizan las paredes de la cavidad, donde el contacto de van der Waals es óptimo. El centro geométrico del bolsillo, lejos de todo átomo, es energéticamente **neutro**: una pose no se estabiliza por estar «en el medio», sino por apoyarse en las paredes.

Campo calculado sobre una rejilla de 320×320 puntos con una sonda de carbono ($\varepsilon = 0.15$, $r_0 = 3.9$ Å) y dieléctrico dependiente de la distancia.

Preparación del ligando y del péptido

Pasos comunes

1. Generación de la estructura 3D desde SMILES o secuencia.
2. **Microespecies** a pH 7.4: estados de protonación dominantes.
3. Enumeración de **tautómeros** y de estereocentros no especificados.
4. Identificación de **enlaces rotables** y construcción del árbol de torsiones.
5. Tipos de átomo y **cargas parciales**.
6. Minimización local y conversión de formato.

Un error frecuente: acoplar la forma neutra de un ácido carboxílico. A pH 7.4 está ionizada, y con ella cambian la carga, el patrón de puentes de hidrógeno y la desolvatación.

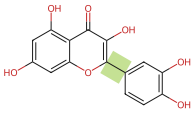
Lo específico de un péptido

- Flexibilidad del **esqueleto** además de las cadenas laterales: ϕ, ψ y ω por residuo.
- Se requiere un ***ensemble*** de partida, no una geometría única.
- La **estructura secundaria** puede formarse *durante* la unión: plegamiento y acoplamiento están acoplados.
- Restricciones por **ciclación**: puentes disulfuro, lactamas, grapas hidrocarbonadas.
- Modificaciones no estándar: N-metilación, D-aminoácidos, acetilación y amidación terminales.

Tratar un péptido como «una molécula pequeña con muchos enlaces rotables» ignora que su conformación de unión frecuentemente no existe de forma estable en disolución.

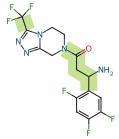
Grados de libertad: evidencia cuantitativa

Estructuras generadas con RDKit; en verde los enlaces rotables



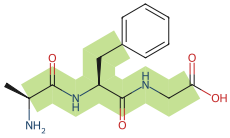
Quercetina

22 átomos pesados · 1 rotable



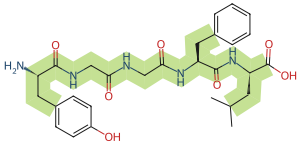
Sitagliptina

27 átomos pesados · 5 rotables



Ala–Phe–Gly

21 átomos pesados · 9 rotables



Leu-encefalina (Tyr–Gly–Gly–Phe–Leu)

40 átomos pesados, 19 enlaces rotables

La tendencia

Un péptido acumula del orden de **3–4 enlaces rotables por residuo** (ϕ, ψ y cadena lateral), frente a 1–2 por grupo funcional en un ligando convencional.

Quercetina y sitagliptina tienen masa comparable a un tripéptido, pero entre **2 y 9 veces** menos grados de libertad torsionales. La masa molecular no predice la dificultad del docking; el número de torsiones sí.

La explosión combinatoria

Tamaño del espacio conformacional

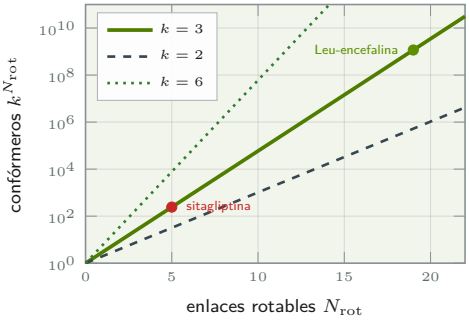
$$N_{\text{conf}} \sim k^{\,N_{\text{rot}}}, \qquad k \approx 3 \text{ (estados por torsión)}$$

- $N_{\text{rot}} = 5$: $3^5 = 243$ confórmeros.
- $N_{\text{rot}} = 15$: $3^{15} \approx 1.4 \times 10^7$.
- $N_{\text{rot}} = 19$: $3^{19} \approx 1.2 \times 10^9$.

Con los seis grados de cuerpo rígido

$$N_{\text{total}} \sim \underbrace{\frac{V}{\delta^3}}_{\text{traslación}} \cdot \underbrace{\frac{8\pi^2}{\Delta\Omega}}_{\text{orientación}} \cdot \underbrace{k^{N_{\text{rot}}}}_{\text{torsiones}}$$

El crecimiento es **exponencial**, no polinomial: ninguna mejora de hardware lo resuelve. Toda estrategia práctica es estocástica o jerárquica, y ninguna garantiza el óptimo global.



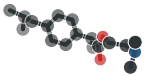
Escala logarítmica: cada torsión adicional multiplica el espacio por k.

Ensembles conformacionales del ligando

14 confórmeros ETKDG superpuestos



Confórmero de menor energía MMFF94



- Los generadores de confórmeros (ETKDG, OMEGA, Confab) cubren el espacio torsional con reglas de distancia derivadas de estructuras experimentales.
- Se filtran por energía y por diversidad: se descartan los confórmeros con RMSD menor a un umbral respecto a otro ya aceptado.

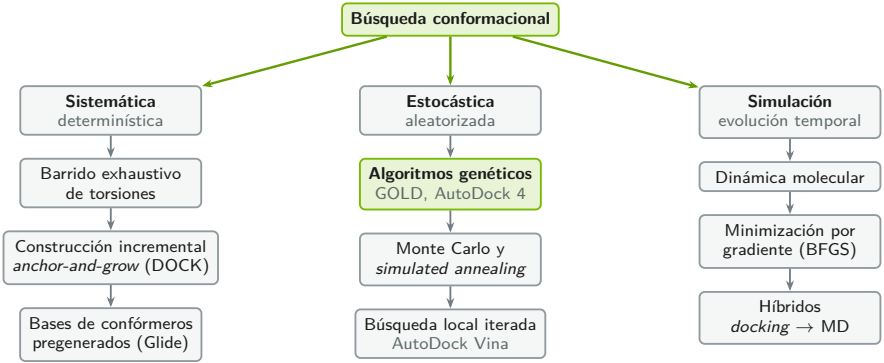
La conformación de unión cuesta energía. El ligando no se une en su confórmero de mínima energía libre: adopta uno de mayor energía interna porque la interacción con el receptor compensa esa tensión. Esa diferencia, $\Delta E_{\text{tensión}} = E_{\text{unido}} - E_{\min}$, suele valer entre 1 y 5 kcal mol^{-1} y rara vez se contabiliza en la puntuación.

Criterio de poda

aceptar $c_i \iff \min_{j<i} \mathrm{RMSD}(c_i, c_j) > \rho \;\wedge\; E_i - E_{\min} < \Delta E_{\max}$

Por eso un *ensemble* demasiado podado puede excluir justamente la conformación bioactiva: el umbral $\Delta E_{\max}$ debe ser generoso, típicamente 10–15 kcal mol^{-1}.

Taxonomía de los algoritmos de búsqueda



Compromiso universal: exhaustividad ↔ costo computacional

Monte Carlo y *simulated annealing*

Criterio de Metropolis

$$P_{\text{acep}} = \min\left\{1,\ \exp\left(-\frac{\Delta E}{k_B T}\right)\right\}$$

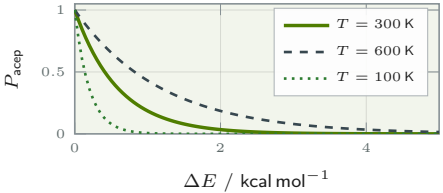
Lectura: si el movimiento baja la energía se acepta siempre; si la sube, se acepta con probabilidad de Boltzmann. Aceptar movimientos desfavorables es lo que permite *salir* de un mínimo local.

Esquema de enfriamiento

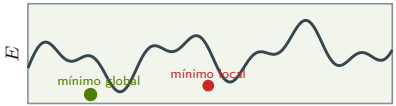
$$T_{k+1} = \gamma\, T_k, \qquad \gamma \in [0.90,\ 0.99]$$

- T alta: exploración amplia, casi aleatoria.
- T baja: refinamiento, el sistema cae al mínimo más cercano.
- **Vina** combina perturbación aleatoria, minimización BFGS y aceptación tipo Metropolis.

Probabilidad de aceptación



Paisaje energético rugoso

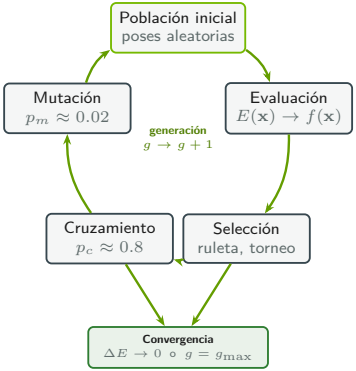


Algoritmos genéticos: fundamentos

- Cada **individuo** es una pose completa; el conjunto forma la **población**.
- El **cromosoma** codifica los $6 + N$ grados de libertad como genes reales.
- La **aptitud** se deriva de la energía de interacción:

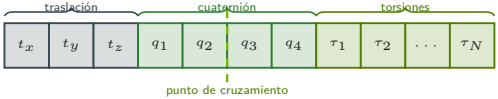
$$f(\mathbf{x}) = \frac{1}{1 + E(\mathbf{x})} \qquad \text{o} \qquad f(\mathbf{x}) = -E(\mathbf{x})$$

- **Operadores**
  - *selección*: ruleta, torneo, elitismo;
  - *cruzamiento*: intercambio de bloques de genes;
  - *mutación*: $\tau_i \leftarrow \tau_i + \mathcal{N}(0, \sigma^2)$.
- Variante **lamarckiana** (AutoDock 4): cada individuo se minimiza localmente y el resultado se escribe de vuelta en el genotipo, lo que acelera mucho la convergencia.



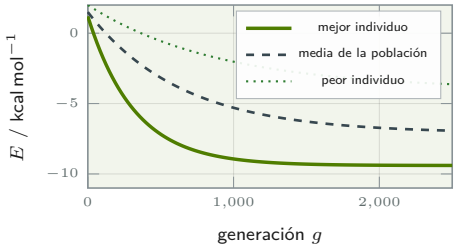
Algoritmos genéticos: codificación y parámetros

Cromosoma de una pose



Parámetro	Rango habitual
Tamaño de población	50–250 individuos
Generaciones	2.5×10^3–2.7×10^4
Evaluaciones de energía	10^5–2.5×10^7
Probabilidad de cruzamiento	$p_c \approx 0.80$
Probabilidad de mutación	$p_m \approx 0.02$
Corridas independientes	10–100

Convergencia (esquemática)



Criterios de convergencia: estancamiento energético, RMSD < 0.5 Å entre los mejores individuos, o agotamiento del presupuesto de evaluaciones.

El indicador práctico más fiable no es ninguno de los anteriores, sino el **acuerdo entre corridas independientes**. Si diez corridas con semillas distintas convergen a la misma pose, el muestreo fue suficiente.

Funciones de *scoring*: cuatro familias

Campo de fuerzas

Suma de términos físicos con parámetros de un campo de fuerzas clásico.

Ej.: AMBER, CHARMM, GoldScore, DOCK.

\+ Interpretable término a término.

− Solvatación y entropía mal descritas.

Empírica

Descriptores ponderados, con pesos ajustados por regresión a afinidades medidas.

Ej.: ChemScore, GlideScore, X-Score, Vina.

\+ Rápida y bien calibrada.

− Hereda los sesgos del entrenamiento.

Conocimiento

Potenciales estadísticos derivados de frecuencias de contacto en el PDB.

Ej.: PMF, DrugScore, ITScore.

\+ No requiere afinidades.

− Estado de referencia discutible.

Aprendida

Modelos de *machine learning* sobre descriptores estructurales.

Ej.: RF-Score, redes 3D convolucionales.

\+ Mejor correlación en prueba.

− Generaliza mal fuera del dominio.

Lo que todas comparten. Evalúan *una* pose estática y aproximan una energía libre —una magnitud que involucra promedios sobre un ensamble— mediante una suma de términos independientes. Esa es la aproximación central del docking, y la razón de fondo de su error típico de 1.5–2.5 kcal mol^{-1}.

Van der Waals: de dónde salen r_0 y ε

Potencial de Lennard-Jones, dos formas equivalentes

$$E = 4\varepsilon\left[\left(\frac{\sigma}{r}\right)^{12} - \left(\frac{\sigma}{r}\right)^{6}\right] = \varepsilon\left[\left(\frac{r_0}{r}\right)^{12} - 2\left(\frac{r_0}{r}\right)^{6}\right]$$

Condición de mínimo

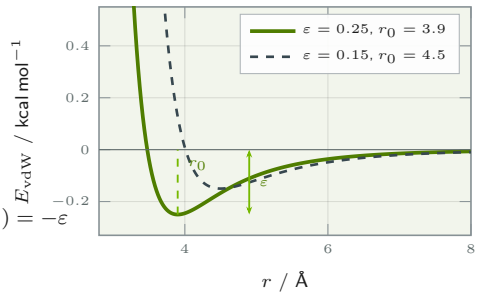
$$\left.\frac{dE}{dr}\right|_{r_0} = \frac{12\varepsilon}{r_0}\left[-\left(\frac{r_0}{r}\right)^{13} + \left(\frac{r_0}{r}\right)^{7}\right]_{r_0} = 0 \;\Rightarrow\; r_0 = 2^{1/6}\sigma, \qquad E(r_0) = -\varepsilon$$

Lectura: ε es la profundidad del pozo y r_0 la distancia óptima. El exponente 12 no tiene justificación física: es el cuadrado de r^{-6} y abarata el cálculo.

Reglas de combinación (Lorentz–Berthelot)

$$r_{0,ij} = \tfrac{1}{2}(r_{0,i} + r_{0,j}), \quad \varepsilon_{ij} = \sqrt{\varepsilon_i \varepsilon_j}$$

Potencial de Lennard-Jones



En docking se suele **suavizar** la pared repulsiva (exponente 8–4 en lugar de 12–6, o truncamiento). Un r^{-12} estricto castiga tanto los choques pequeños que la pose correcta, con un solapamiento de 0.2 Å, puede quedar descartada.

Electrostática en medio proteico

Coulomb con apantallamiento

$$E_{\text{elec}} = 332.0 \sum_{i<j} \frac{q_i q_j}{\epsilon(r_{ij})\, r_{ij}} \quad [\text{kcal mol}^{-1}]$$

Lectura: el factor 332.0 convierte a kcal mol^{-1} con cargas en unidades elementales y r en Å.

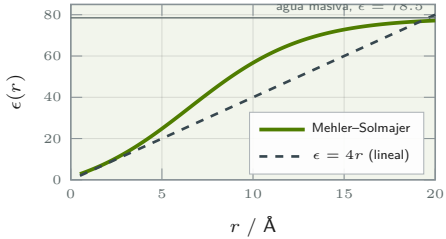
Dieléctrico dependiente de la distancia

$$\epsilon(r) = A + \frac{B}{1 + k\, e^{-\lambda B r}}$$

Mehler–Solmajer: $A = -8.5525$, $B = 86.9525$, $\lambda = 0.003627$, $k = 7.7839$

Lectura: cerca, $\epsilon \approx 4$, como en el interior apolar de una proteína; lejos, $\epsilon \approx 78$, como en agua. Imita el apantallamiento del disolvente sin modelarlo.

Constante dieléctrica efectiva



Por qué importa tanto. Un puente salino vale decenas de kcal mol^{-1} en el vacío y apenas 1–2 en agua, porque ambos iones estaban bien solvatados y hay que desnudarlos. Una función que no descuente bien la desolvatación **sobrevalora sistemáticamente** los ligandos cargados.

Solvatación implícita

Born generalizado

$$\Delta G_{\text{pol}} = -\tfrac{1}{2}\left(1 - \tfrac{1}{\epsilon_w}\right) \sum_{i,j} \frac{q_i q_j}{f_{\text{GB}}(r_{ij}, \alpha_i, \alpha_j)}$$

$$f_{\text{GB}} = \sqrt{r_{ij}^2 + \alpha_i \alpha_j \, e^{-r_{ij}^2 / 4\alpha_i \alpha_j}}$$

Lectura: α_i es el radio de Born efectivo: mide cuán enterrado está el átomo i. Un átomo superficial se solvata bien; uno profundo, no.

Poisson–Boltzmann linealizada

$$\nabla \cdot \Big[\epsilon(\mathbf{r}) \nabla \phi(\mathbf{r})\Big] - \epsilon\, \kappa^2 \phi(\mathbf{r}) = -4\pi \rho(\mathbf{r})$$

κ^{-1}: longitud de Debye, fija la fuerza iónica

Desolvatación de volumen (tipo AutoDock)

$$\Delta G_{\text{desolv}} = \sum_{i,j} \left(S_i V_j + S_j V_i\right) e^{-r_{ij}^2 / 2\sigma^2}$$

S: parámetro de solvatación atómica · V: volumen · $\sigma \approx 3.5\,\text{Å}$

Lectura: cada átomo desplaza el agua que rodeaba al otro; el término escala con el volumen desplazado.

Término no polar: el efecto hidrofóbico

$$\Delta G_{\text{np}} = \gamma\, \Delta\text{SASA} + b, \qquad \gamma \approx 0.005\text{–}0.025$$

en kcal mol^{-1} Å^{-2}; SASA: área accesible al disolvente

Costo relativo. $\epsilon(r)$ es gratis, GB $\sim 10\times$, PB 10^2–$10^3\times$: de ahí que el docking use la primera y el refinamiento las otras.

Puente de hidrógeno: distancia y dirección

Término 12–10 con factor angular

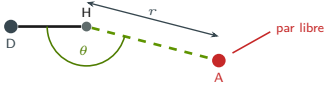
$$E_{\text{hb}} = \left(\frac{C}{r^{12}} - \frac{D}{r^{10}} \right) E(\theta)$$

Posición del mínimo

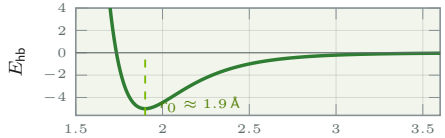
$$\frac{dE}{dr} = 0 \;\Rightarrow\; r_0 = \sqrt{\frac{12\,C}{10\,D}} = \sqrt{1.2\,\frac{C}{D}} \approx 1.9\,\text{Å}$$

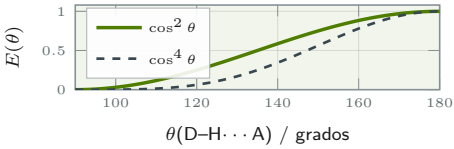
Lectura: el exponente 10 en vez de 6 hace el pozo más estrecho que el de van der Waals: el puente de hidrógeno es una interacción *corta y exigente* en geometría.

- Geometría óptima: $d(\text{H}\cdots\text{A}) \approx 1.9\,\text{Å}$, $\theta(\text{D}{-}\text{H}\cdots\text{A}) \to 180°$.
- Energía típica en proteínas: 1–5 kcal mol^{-1}, muy reducida respecto al vacío por la competencia del agua.



Dependencia radial 12–10





La entropía: el término que casi nadie calcula bien

Al formarse el complejo, el sistema **pierde entropía** por tres vías distintas.

1. Traslacional y rotacional

$$-T\Delta S_{\text{tr+rot}} \approx +10 \text{ a } 15 \text{ kcal mol}^{-1}$$

dos cuerpos independientes pasan a ser uno

2. Conformacional del ligando

$$-T\Delta S_{\text{conf}} \approx W_{\text{tor}}\, N_{\text{tor}}, \qquad W_{\text{tor}} = 0.2983$$

coeficiente de AutoDock 4, en kcal mol^{-1} por torsión congelada

3. Del disolvente: el efecto hidrofóbico

$$\Delta G_{\text{np}} = \gamma\, \Delta\text{SASA} + b, \qquad \gamma \approx 0.005\text{–}0.025$$

en $\text{kcal mol}^{-1}\,\text{Å}^{-2}$; aquí la entropía *favorece* la unión

El balance es delicado. Los términos 1 y 2 se oponen a la unión y suman fácilmente $+15$ kcal mol^{-1}; el término 3 y la entalpía de contacto la favorecen. La energía libre neta de un buen fármaco es apenas -10 kcal mol^{-1}: una **pequeña diferencia entre números grandes**. Por eso el error relativo de cualquier estimación es alto.

Eficiencia del ligando. Para comparar moléculas de tamaño distinto se normaliza por número de átomos pesados:

$$\text{LE} = \frac{-\Delta G}{N_{\text{pesados}}} \quad [\text{kcal mol}^{-1}\ \text{átomo}^{-1}]$$

Un valor $\text{LE} \gtrsim 0.3$ se considera buen punto de partida. Añadir átomos casi siempre mejora ΔG; mejorar LE es lo difícil.

Por qué se usa N_{tor} y no la entropía real. Calcular ΔS exige muestrear el ensamble completo del ligando libre y unido. En docking se sustituye por un término lineal en el número de torsiones: barato, grosero y suficiente para ordenar.

Función semiempírica completa: AutoDock 4

Energía libre de unión como suma pesada

$$\Delta G = W_{\text{vdW}} \sum_{i,j} \left(\frac{A_{ij}}{r_{ij}^{12}} - \frac{B_{ij}}{r_{ij}^{6}} \right) + W_{\text{hb}} \sum_{i,j} E(t) \left(\frac{C_{ij}}{r_{ij}^{12}} - \frac{D_{ij}}{r_{ij}^{10}} \right)$$
$$+ W_{\text{elec}} \sum_{i,j} \frac{q_i q_j}{\epsilon(r_{ij})\, r_{ij}} + W_{\text{sol}} \sum_{i,j} \left(S_i V_j + S_j V_i \right) e^{-r_{ij}^2 / 2\sigma^2} + W_{\text{tor}} N_{\text{tor}}$$

Término	Peso	Qué captura
W_{vdW}	0.1662	forma y contacto
W_{hb}	0.1209	direccionalidad
W_{elec}	0.1406	carga
W_{sol}	0.1322	desolvatación
W_{tor}	0.2983	entropía torsional

De dónde salen los pesos. Se ajustan por mínimos cuadrados contra un conjunto de complejos con estructura cristalográfica *y* afinidad medida. Los cuatro primeros términos tienen unidades de energía y los pesos son adimensionales: su papel es corregir el doble conteo entre términos y calibrar la escala.

El ajuste se hizo sobre un conjunto concreto. Un sistema que se aparte de ese dominio —metaloenzimas, interfaces muy polares, ligandos macrocíclicos— cae fuera de la calibración, y la puntuación pierde significado cuantitativo.

Función empírica por trozos: AutoDock Vina

Vina prescinde de cargas y define la interacción sobre la **distancia de superficie** $d_{ij} = r_{ij} - R_i - R_j$, con R el radio de van der Waals.

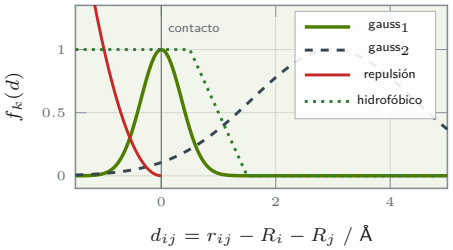
Los cinco términos

$\text{gauss}_1 = e^{-(d/0.5)^2}$	$w_1 = -0.0356$
$\text{gauss}_2 = e^{-((d-3)/2)^2}$	$w_2 = -0.00516$
$\text{repulsión} = d^2 \quad [d < 0]$	$w_3 = +0.840$
$\text{hidrofóbico} = \mathbb{1}[d < 0.5]$ (rampa)	$w_4 = -0.0351$
$\text{Hbond} = \mathbb{1}[d < -0.7]$ (rampa)	$w_5 = -0.587$

Afinidad final

$$\Delta G = \frac{\sum_{i<j} w_k \, f_k(d_{ij})}{1 + w_{\text{rot}} N_{\text{rot}}}, \qquad w_{\text{rot}} = 0.0585$$

Los términos de Vina



Por qué funciona siendo tan simple. Al trabajar con d_{ij} en lugar de r_{ij}, el mismo término sirve para átomos de tamaños distintos. Y al prescindir de cargas evita el problema peor calibrado de todos: la electrostática con desolvatación.

Potenciales estadísticos: inversión de Boltzmann

Si en el PDB un par de átomos aparece a cierta distancia **con más frecuencia de la esperada al azar**, esa distancia debe ser favorable.

Potencial de fuerza media

$$w_{ij}(r) = -k_B T \ln\left[\frac{g_{ij}(r)}{g^{\text{ref}}(r)}\right] = -k_B T \ln\left[\frac{\rho_{ij}^{\text{obs}}(r)}{\rho_{ij}^{\text{ref}}(r)}\right]$$

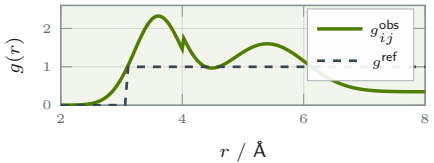
Lectura: se invierte la relación de Boltzmann: en vez de deducir poblaciones desde energías, se deducen energías desde poblaciones.

Puntuación total

$$S = \sum_{i \in \text{lig}} \sum_{j \in \text{prot}} w_{t(i)t(j)}\left(r_{ij}\right)$$

El punto débil: el estado de referencia. g^{ref} representa «qué esperaríamos sin interacción», y no hay definición única: distintas elecciones dan potenciales distintos con los mismos datos.

Función de distribución radial



Potencial derivado

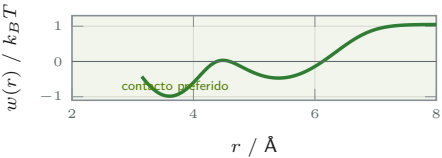


Ilustración del procedimiento: un pico en $g(r)$ se traduce en un pozo en $w(r)$.

Funciones aprendidas: promesa y advertencia

- En lugar de postular una forma funcional, se **aprende** la relación entre descriptores estructurales y afinidad:

$$\Delta G = f_\theta\left(\mathbf{x}_{\text{complejo}}\right)$$

- **RF-Score**: bosques aleatorios sobre conteos de pares de tipos atómicos dentro de un radio de corte.
- **Redes 3D convolucionales**: el complejo se discretiza en una rejilla con canales por tipo de átomo, como si fuera una imagen volumétrica.
- **Redes de grafos**: átomos como nodos, enlaces y contactos como aristas.

Mejoran claramente la correlación con la afinidad en conjuntos de prueba estándar, superando a las funciones clásicas en los *benchmarks* publicados.

La advertencia metodológica. Buena parte de esa mejora desaparece cuando entrenamiento y prueba se separan por **similitud de proteína o de ligando**. El modelo puede estar aprendiendo a reconocer *qué* proteína es, no *por qué* une: memoriza el nivel de afinidad típico de esa familia.

Cómo evaluar honestamente un modelo aprendido

- partición por secuencia (identidad $< 30\,\%$) y por andamiaje de Bethge;
- comparar contra una línea base tonta: masa molecular, número de átomos pesados;
- probar en una diana que no esté en el entrenamiento.

Si un modelo no supera a «número de átomos pesados» en una diana nueva, no está aprendiendo química de la unión.

De la puntuación a la afinidad: los límites

Lo que querríamos

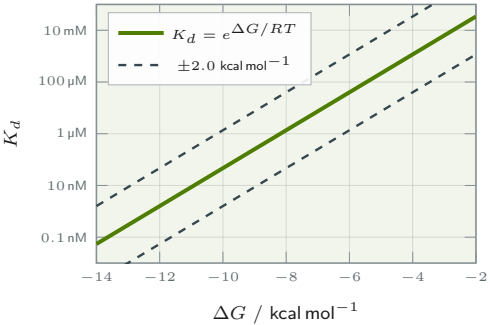
$$\Delta G^\circ = -RT \ln K_a, \qquad K_d = e^{\Delta G^\circ / RT}$$

- A 298 K, $RT = 0.592$ kcal mol^{-1}.
- Error típico de una función de *scoring*: **1.5–2.5 kcal mol^{-1}**.
- Eso corresponde a **uno o dos órdenes de magnitud** en K_d.

Consecuencia operativa. Las puntuaciones sirven para *ordenar* y para descartar lo claramente malo. No sirven para afirmar que un compuesto con -9.4 es mejor que otro con -9.1: esa diferencia está muy por debajo del ruido del método.

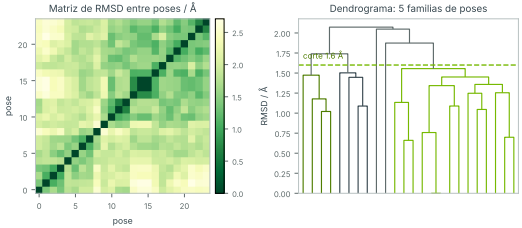
Tampoco son comparables entre programas: cada función tiene su propia escala. Un -8 de Vina y un -8 de GlideScore no significan lo mismo.

Sensibilidad de K_d al error en ΔG



La banda azul es el error típico de una función de *scoring*: abarca más de tres órdenes de magnitud en K_d.

RMSD y *clustering* de poses



Desviación cuadrática media, corregida por simetría

$$\mathrm{RMSD} = \min_{\pi \in \mathcal{A}} \sqrt{\frac{1}{N} \sum_{i=1}^{N} \left\| \mathbf{r}_i - \mathbf{r}^{0}_{\pi(i)} \right\|^2}$$

Lectura: $\mathcal{A}$ son los automorfismos del grafo molecular. Sin esa minimización, girar un fenilo 180° daría un RMSD falsamente alto.

Criterios de éxito (átomos pesados): ≤ 2.0 Å correcta; ≤ 1.0 Å excelente; > 3.0 Å fallo. En péptidos se informa por separado el RMSD de esqueleto y el de cadenas laterales.

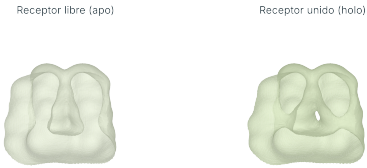
El tamaño del grupo importa tanto como la energía. Una pose aislada con la mejor puntuación es menos confiable que el representante de un grupo numeroso: la densidad de soluciones en torno a una pose indica que el embudo energético es ancho y la encuentra desde muchos puntos de partida.

Matriz y dendrograma calculados sobre 24 confórmeros reales (RMSD con corrección por simetría, enlace promedio, corte a 1.6 Å).

Validación del protocolo y flexibilidad del receptor

1. ***Redocking***: se retira el ligando co-cristalizado y se vuelve a acoplar sobre su propio receptor. Es la prueba mínima; un RMSD $> 2\,\text{Å}$ invalida el protocolo antes de empezar.
2. ***Cross-docking***: se acopla el ligando sobre estructuras del receptor obtenidas con *otros* ligandos. Mide la sensibilidad a la conformación del sitio, y los resultados suelen ser bastante peores.
3. **Cribado retrospectivo**: capacidad de recuperar activos conocidos mezclados con señuelos.

Un *redocking* exitoso demuestra que el protocolo funciona **en el caso más fácil posible**: el receptor ya tiene la forma del ligando. No garantiza nada sobre un ligando nuevo.



Superficies calculadas para dos conformaciones del mismo receptor: la cavidad se abre al unir.

Cómo incorporar la flexibilidad

- *cadenas laterales flexibles*: unos pocos residuos del sitio se tratan como rotables;
- *ensemble docking*: se acopla contra varias estructuras (cristalográficas o de MD) y se combina el resultado;
- *soft docking*: término repulsivo suavizado;
- *refinamiento con MD* tras acoplar.

Cribado virtual: cómo se mide el éxito

Factor de enriquecimiento

$$\mathrm{EF}_{x\%} = \frac{A_x / N_x}{A_{\text{tot}} / N_{\text{tot}}}$$

A_x: activos en el $x\%$ mejor ordenado · N_x: compuestos en ese $x\%$

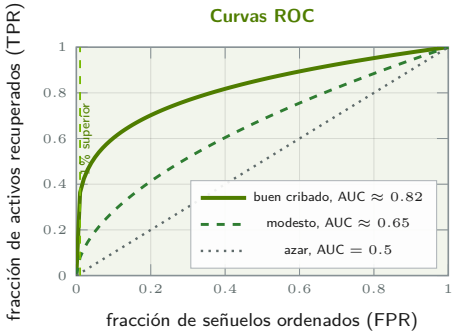
Lectura: $\mathrm{EF}_{1\%} = 20$ significa que en el 1 % superior de la lista hay 20 veces más activos que si hubiéramos elegido al azar.

Área bajo la curva ROC

$$\mathrm{AUC} = P\big(s_{\text{activo}} > s_{\text{señuelo}}\big)$$

0.5 = azar · 1.0 = separación perfecta

AUC es una medida *global*; en cribado sólo interesa el principio de la lista, porque sólo eso se compra y se ensaya. Por eso se prefieren EF a 1 % o métricas con peso exponencial temprano (BEDROC, RIE).



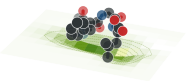
Cuidado con los señuelos. Si los señuelos difieren de los activos en propiedades triviales —masa, carga, logP— el método puede «acertar» sin usar información estructural. Conjuntos como DUD-E los emparejan por propiedades justamente para evitarlo.

Por qué un péptido no es «un ligando grande»

Ligando: cavidad profunda y cerrada



Péptido: interfaz extensa y somera



	Molécula pequeña	Péptido
Enlaces rotables	1–10	3–4 por residuo; >15 habitual
Esqueleto	restringido por anillos	ϕ, ψ libres; se pliega al unirse
Tipo de sitio	cavidad **profunda**	interfaz **somera** y extendida
Área enterrada	300–600 Å^2	800–2000 Å^2
Naturaleza de la unión	pocos contactos intensos	muchos contactos débiles
Consecuencia	muestreo tratable, *scoring* calibrado	muestreo costoso, *scoring* fuera de dominio

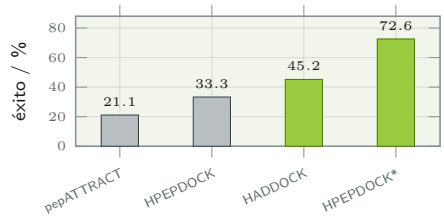
Dificultades específicas y métodos propios

1. **Muestreo insuficiente**: el espacio crece exponencialmente con la longitud.
2. ***Scoring* fuera de dominio**: las funciones se ajustaron con complejos proteína–ligando pequeño y subestiman las interfaces extensas.
3. **Solvatación dominante**: el área enterrada es dos a tres veces mayor, y los errores de desolvatación escalan con ella.
4. **Entropía conformacional**: la pérdida al plegarse rara vez se modela explícitamente.
5. **Sitio desconocido**: muchos casos exigen docking ciego.



Confórmero MMFF94 de Leu-encefalina y hélice α ideal.

Modo de unión correcto (10 mejores modelos)



Gris: docking *ciego* global (57 casos *unbound*). Verde: docking *local* con sitio conocido (62 casos). Datos: Zhou *et al.*, *Nucleic Acids Res.* **46**, W443 (2018).

Conocer el sitio de unión duplica la tasa de éxito. La diferencia entre docking ciego y local es, en la práctica, mayor que la diferencia entre programas.

CABS-dock (grano grueso, sin sitio predefinido), **HPEPDOCK** (jerárquico), **FlexPepDock** (refinamiento Rosetta), **ADCP** (macrociclos).

Refinamiento: MD, MM-PBSA y energía libre alquímica

MM-PBSA / MM-GBSA

$$\Delta G_{\text{unión}} = \Delta E_{\text{MM}} + \Delta G_{\text{solv}} - T\Delta S$$

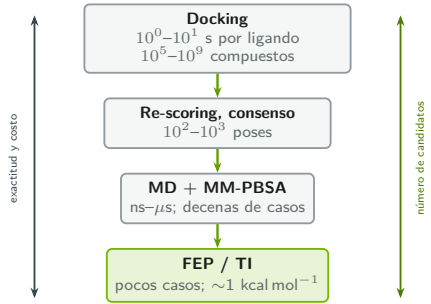
$$\Delta E_{\text{MM}} = \Delta E_{\text{vdW}} + \Delta E_{\text{elec}}, \quad \Delta G_{\text{solv}} = \Delta G_{\text{PB/GB}} + \gamma\,\Delta\text{SASA}$$

Lectura: se promedia sobre instantáneas de una trayectoria de MD, de modo que el resultado ya no depende de una sola pose estática.

Relación de Zwanzig (perturbación de energía libre)

$$\Delta G_{0\to 1} = -k_B T \ln \left\langle e^{-\Delta U / k_B T} \right\rangle_0$$

Lectura: se transforma gradualmente un ligando en otro mediante un parámetro de acoplamiento λ, y se acumula el trabajo. Es el método más exacto disponible y alcanza ~ 1 kcal mol^{-1}, pero cuesta órdenes de magnitud más.



Consenso. Combinar varias funciones de *scoring* (suma de rangos, votación) suele ser más robusto que confiar en una, porque los errores de funciones con fundamentos distintos están parcialmente descorrelacionados.

Errores frecuentes y buenas prácticas

Errores que invalidan un estudio

- No validar con *redocking* y reportar sólo la mejor puntuación obtenida.
- Acoplar el ligando en su forma neutra cuando a pH 7.4 está ionizado.
- Dejar la histidina con el tautómero que el programa asignó por omisión.
- Una sola corrida, sin semillas ni réplicas.
- Caja de búsqueda tan grande que diluye el muestreo, o tan pequeña que recorta poses válidas.
- Comparar puntuaciones entre programas distintos.
- Concluir afinidad a partir de diferencias de 0.3 kcal mol^{-1}.

Lo que sí sostiene un resultado

- Documentar **todas** las decisiones de preparación: origen y resolución de la estructura, aguas conservadas, protonación, cadena elegida.
- **Múltiples corridas independientes** y reporte de la dispersión, no sólo del mejor valor.
- **Analizar contactos**, no sólo el número: puentes de hidrógeno, puentes salinos, apilamiento π.
- Comprobar la **plausibilidad química** de la pose: grupos cargados enterrados sin contraparte, enlaces tensionados, estereoquímica alterada.
- Contrastar con **evidencia experimental**: mutagénesis, SAR, competencia.

> Una puntuación favorable con una pose químicamente implausible es un resultado negativo, no un hallazgo. El criterio estructural prevalece sobre el número.

Conclusiones

Lo esencial

- El docking resuelve dos problemas distintos —muestreo y puntuación— y falla por razones distintas en cada uno.
- Para **moléculas pequeñas** el muestreo rara vez es limitante: la metodología es madura y el problema abierto es la exactitud en afinidad.
- Para **péptidos** ambos son limitantes a la vez, y conocer el sitio de unión es el factor individual más influyente.
- La preparación del sistema —protonación, tautómeros, aguas— determina el resultado tanto como la elección del programa.

Hacia dónde va el campo

- Funciones de *scoring* **aprendidas** con evaluación honesta fuera de dominio.
- Predicción estructural de complejos por **aprendizaje profundo** como generador de poses de partida.
- Protocolos **híbridos**: docking $\rightarrow$ MD $\rightarrow$ energía libre, cada etapa filtrando para la siguiente.
- Representaciones de **grano grueso** para muestrear plegamiento y unión de forma acoplada.
- Integración de **restricciones experimentales** (RMN, entrecruzamiento, mutagénesis) dentro del muestreo.

El docking produce **hipótesis estructurales**. Su utilidad se mide por cuántas resisten la prueba experimental, no por la magnitud del número que devuelve.

Síntesis de ecuaciones

Optimización $(\mathbf{t}^*, \boldsymbol{\Omega}^*, \boldsymbol{\tau}^*) = \arg\min E(\mathbf{t}, \boldsymbol{\Omega}, \boldsymbol{\tau})$

Espacio conf. $N_{\text{conf}} \sim k^{N_{\text{rot}}}, \quad k \approx 3$

Afinidad $\Delta G^\circ = -RT \ln K_a = -1.364\,\text{p}K_d$

van der Waals $E = \varepsilon \left[(r_0/r)^{12} - 2(r_0/r)^6 \right], \; r_0 = 2^{1/6}\sigma$

Electrostática $E = 332 \sum_{i<j} \frac{q_i q_j}{\epsilon(r_{ij})\, r_{ij}}$

Puente de H $E = \left(Cr^{-12} - Dr^{-10} \right) E(\theta)$

Desolvatación $\sum_{i,j} (S_i V_j + S_j V_i)\, e^{-r_{ij}^2 / 2\sigma^2}$

Entropía tors. $-T\Delta S_{\text{conf}} \approx W_{\text{tor}} N_{\text{tor}}$

Metropolis $P = \min\{1,\, e^{-\Delta E / k_B T}\}$

Boltzmann inv. $w(r) = -k_B T \ln \left[g^{\text{obs}}(r) / g^{\text{ref}}(r) \right]$

RMSD $\min_{\pi} \sqrt{\frac{1}{N} \sum_i \| \mathbf{r}_i - \mathbf{r}^0_{\pi(i)} \|^2}$

Enriquecimiento $\text{EF}_{x\%} = \frac{A_x / N_x}{A_{\text{tot}} / N_{\text{tot}}}$

Referencias (1/2)

1. Trott, O.; Olson, A. J. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *J. Comput. Chem.* **2010**, *31*, 455–461. doi:10.1002/jcc.21334
2. Morris, G. M.; *et al.* AutoDock4 and AutoDockTools4: automated docking with selective receptor flexibility. *J. Comput. Chem.* **2009**, *30*, 2785–2791.
3. Halgren, T. A. Merck molecular force field. I. Basis, form, scope, parameterization, and performance of MMFF94. *J. Comput. Chem.* **1996**, *17*, 490–519.
4. Jones, G.; Willett, P.; Glen, R. C.; Leach, A. R.; Taylor, R. Development and validation of a genetic algorithm for flexible docking. *J. Mol. Biol.* **1997**, *267*, 727–748.
5. Mehler, E. L.; Solmajer, T. Electrostatic effects in proteins: comparison of dielectric and charge models. *Protein Eng.* **1991**, *4*, 903–910.
6. Kurcinski, M.; Jamroz, M.; Blaszczyk, M.; Kolinski, A.; Kmiecik, S. CABS-dock web server for the flexible docking of peptides to proteins without prior knowledge of the binding site. *Nucleic Acids Res.* **2015**, *43*, W419–W424. doi:10.1093/nar/gkv456

Referencias (2/2)

7. Zhou, P.; Jin, B.; Li, H.; Huang, S.-Y. HPEPDOCK: a web server for blind peptide–protein docking based on a hierarchical algorithm. *Nucleic Acids Res.* **2018**, *46*, W443–W450. doi:10.1093/nar/gky357
8. Tao, H.; Zhao, X.; Zhang, K.; Lin, P.; Huang, S.-Y. Docking cyclic peptides formed by a disulfide bond through a hierarchical strategy. *Bioinformatics* **2022**, *38*, 4109–4116. doi:10.1093/bioinformatics/btac486
9. London, N.; Raveh, B.; Cohen, E.; Fathi, G.; Schueler-Furman, O. Rosetta FlexPepDock web server — high resolution modeling of peptide–protein interactions. *Nucleic Acids Res.* **2011**, *39*, W249–W253. doi:10.1093/nar/gkr431
10. Raveh, B.; London, N.; Zimmerman, L.; Schueler-Furman, O. Rosetta FlexPepDock ab-initio: simultaneous folding, docking and refinement of peptides onto their receptors. *PLoS ONE* **2011**, *6*, e18934. doi:10.1371/journal.pone.0018934
11. Schindler, C. E. M.; Chauvot de Beauchêne, I.; de Vries, S. J.; Zacharias, M. Protein–protein and peptide–protein docking and refinement using ATTRACT in CAPRI. *Proteins* **2017**, *85*, 391–398. doi:10.1002/prot.25196
12. Blaszczyk, M.; Ciemny, M. P.; Kolinski, A.; Kurcinski, M.; Kmiecik, S. Protein–peptide docking using CABS-dock and contact information. *Brief. Bioinform.* **2019**, *20*, 2299–2305. doi:10.1093/bib/bby080

Referencias 1, 6–12 recuperadas de PubMed. Estructuras moleculares y superficies generadas con RDKit, NumPy, scikit-image y Matplotlib; diagramas elaborados en TikZ/PGFPlots.

Gracias

Preguntas y discusión

Osvaldo Yáñez

Centro de Modelación Ambiental y Dinámica de Sistemas